

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP

KHOA ĐIỆN TỬ

Bộ môn: Công nghệ Thông tin.



BÀI TIỂU LUẬN
MÔN HỌC
KHOA HỌC DỮ LIỆU

Sinh viên: Nguyễn Đình Tú

Lớp: K58KTP

Giáo viên hướng dẫn: TS.Nguyễn Văn Huy

Thái Nguyên – 2026

PHIẾU GIAO ĐỀ TÀI KHOA HỌC DỮ LIỆU

Họ tên sinh viên: Nguyễn Đình Tú MSSV: k225480106067

Chuyên ngành KTPM Lớp học phần K58KTP

TÊN ĐỀ TÀI: Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam

1. Bộ dữ liệu gì :
2. 5 câu hỏi về phân tích dữ liệu sẽ trả lời là gì?
3. 2 câu hỏi về dự đoán, hoặc phân cụm, hoặc phân lớp sẽ trả lời là gì?
4. Link github chứa 04 nội dung sau:
 1. Code toàn bộ chương trình
 2. Link youtube video trình bày kết quả. Nội dung trình bày
 - Giới thiệu tên, môn học, tên đề tài, Giáo viên dạy
 - Giới thiệu mục đích chính của đề tài
 - Cách làm và kết quả
 3. Slide powerpoint
 4. Báo cáo word

Ngày giao nhiệm vụ: 31 / 05/2026

Ngày hoàn thành nhiệm vụ: / 06/2026

Họ và tên cán bộ hướng dẫn: Nguyễn Văn Huy

BM. CÔNG NGHỆ THÔNG TIN

CÁN BỘ HƯỚNG DẪN

TRƯỜNG ĐHKT CÔNG NGHIỆP
BỘ MÔN CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập - Tự do - Hạnh phúc

----o0o----

PHIẾU GHI ĐIỂM

BÀI TIỂU LUẬN KHOA HỌC DỮ LIỆU

Sinh viên: Nguyễn Đình Tú

Mssv: K225480106067

Ngành học: Kỹ thuật máy tính

Lớp: K58.KTP

GVHD: GV Nguyễn Văn Huy

Đề tài: Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....
.....
.....
.....

Xếp loại: Điểm :

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

MỤC LỤC

LỜI CAM ĐOAN	5
DANH MỤC CÁC TỪ VIẾT TẮT	6
DANH MỤC CÁC BẢNG VÀ HÌNH VẼ, ĐỒ THỊ	7
LỜI NÓI ĐẦU	8
LỜI CẢM ƠN	9
CHƯƠNG 1: TỔNG QUAN	10
1.1. Đặt vấn đề	10
1.2. Lý do chọn đề tài	10
1.3. Mục tiêu của đề tài	11
1.3.1. Mục tiêu tổng quát	11
1.3.2. Mục tiêu cụ thể	11
1.4. Phạm vi nghiên cứu	12
1.5. Phương pháp nghiên cứu	13
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	14
2.1. Tổng quan về Khoa học dữ liệu	14
2.2. Phân tích dữ liệu khám phá (EDA)	15
2.3. Học máy trong phân tích dữ liệu	16
2.3.1. Bài toán phân lớp	17
2.3.2. Bài toán phân cụm	18
2.4. Một số thuật toán sử dụng trong đề tài	19
2.4.1. Thuật toán Random Forest	19
2.4.2. Thuật toán K-Means	20
CHƯƠNG 3: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG	22
3.1. Kiến trúc hệ thống phân tích dữ liệu	22
3.1.1. Sơ đồ khối hệ thống	22
3.1.2. Quy trình hoạt động của hệ thống	23
3.1.3. Các chức năng chính của hệ thống	24
3.2. Thiết kế thuật toán	25
3.2.1. Thuật toán tiền xử lý dữ liệu	25
3.2.2. Thuật toán phân tích dữ liệu khám phá (EDA)	26

3.2.3. Thuật toán phân lớp Random Forest	27
3.2.4. Thuật toán phân cụm K-Means	29
3.3. Thiết kế dữ liệu	30
3.3.1. Giới thiệu bộ dữ liệu IT Jobs Dataset	30
3.3.2. Mô tả các trường dữ liệu	31
3.3.3. Các thuộc tính được sử dụng trong nghiên cứu	32
3.4. Xây dựng hệ thống	32
3.4.1. Môi trường phát triển	32
3.4.2. Xây dựng chương trình xử lý dữ liệu	33
3.4.3. Xây dựng mô hình học máy	34
3.4.4. Giao diện và kết quả hiển thị	34
CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	36
4.1. Thực nghiệm	36
4.1.1. Kết quả phân tích nhu cầu tuyển dụng theo thành phố	36
4.1.2. Kết quả phân tích vị trí CNTT được tuyển dụng nhiều nhất	36
4.1.3. Kết quả phân tích kỹ năng CNTT được yêu cầu nhiều nhất	37
4.1.4. Kết quả phân tích mối liên hệ giữa các kỹ năng	38
4.1.5. Kết quả phân tích mối quan hệ giữa số lượng kỹ năng và đánh giá công ty	39
4.1.6. Kết quả mô hình phân lớp Random Forest	40
4.1.7. Kết quả mô hình phân cụm K-Means	41
4.1.8. Đánh giá chung kết quả thực nghiệm	42
4.2. Kết luận	43
4.2.1. Những kết quả đạt được	43
4.2.2. Kiến thức và kỹ năng thu được	43
4.2.3. Hạn chế của đề tài	44
4.2.4. Hướng phát triển	44
TÀI LIỆU THAM KHẢO	45

LỜI CAM ĐOAN

Em xin cam đoan bài tiểu luận “ Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam ” này là công trình nghiên cứu của riêng chúng em. Các số liệu sử dụng trong luận văn là trung thực. Các kết quả nghiên cứu được trình bày trong bài tập lớn chưa từng được công bố tại bất kỳ người nào khác.

Tên sinh viên

Tú

Nguyễn Đình Tú

DANH MỤC CÁC TỪ VIẾT TẮT

1	CNTT	Công nghệ thông tin
2	CSDL	Cơ sở dữ liệu
3	EDA	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
4	ML	Machine Learning (Học máy)
5	AI	Artificial Intelligence (Trí tuệ nhân tạo)
6	CSV	Comma-Separated Values (Tập dữ liệu dạng bảng)
7	RF	Random Forest
8	KNN	K-Nearest Neighbors (Thuật toán K láng giềng gần nhất)
9	SVM	Support Vector Machine (Máy véc-tơ hỗ trợ)
10	API	Application Programming Interface (Giao diện lập trình ứng dụng)
11	SQL	Structured Query Language (Ngôn ngữ truy vấn có cấu trúc)
12	DBMS	Database Management System (Hệ quản trị cơ sở dữ liệu)
13	KPI	Key Performance Indicator (Chỉ số đánh giá hiệu suất)
14	UI	User Interface (Giao diện người dùng)
15	UX	User Experience (Trải nghiệm người dùng)
16	IDE	Integrated Development Environment (Môi trường phát triển tích hợp)
17	CPU	Central Processing Unit (Bộ xử lý trung tâm)
18	RAM	Random Access Memory (Bộ nhớ truy cập ngẫu nhiên)
19	HTML	HyperText Markup Language (Ngôn ngữ đánh dấu siêu văn bản)
20	CSS	Cascading Style Sheets (Ngôn ngữ định dạng giao diện web)

DANH MỤC CÁC BẢNG VÀ HÌNH VẼ, ĐỒ THỊ

Hình 3.1: Sơ đồ khối hệ thống phân tích dữ liệu

Hình 3.2. Lưu đồ thuật toán tiền xử lý dữ liệu

Hình 3.3. Lưu đồ thuật toán Random Forest

Hình 3.4. Lưu đồ thuật toán K-Means

Hình 4.1. Biểu đồ số lượng tin tuyển dụng CNTT theo thành phố

Hình 4.2. Biểu đồ những vị trí CNTT được tuyển dụng nhiều nhất

Hình 4.3. Biểu đồ các kỹ năng CNTT được yêu cầu nhiều nhất

Hình 4.4. Biểu đồ kỹ năng xuất hiện nhiều nhất

Hình 4.5. Biểu đồ mối quan hệ giữa số lượng kỹ năng và đánh giá công ty

Hình 4.6. Biểu đồ so sánh nhóm nghề thực tế và nhóm nghề dự đoán bằng Random Forest

Hình 4.7. Biểu đồ số lượng vị trí theo nhóm nghề sau phân cụm K-Means

LỜI NÓI ĐẦU

Trong thời đại chuyển đổi số hiện nay, ngành Công nghệ thông tin (CNTT) đang phát triển mạnh mẽ và trở thành một trong những lĩnh vực có nhu cầu nhân lực cao tại Việt Nam. Sự phát triển của các doanh nghiệp công nghệ cùng với xu hướng ứng dụng CNTT trong mọi lĩnh vực đã tạo ra nhiều cơ hội việc làm, đồng thời đặt ra những yêu cầu mới về kỹ năng và trình độ chuyên môn đối với người lao động.

Xuất phát từ thực tế đó, đề tài “Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam” được thực hiện nhằm thu thập, xử lý và phân tích dữ liệu tuyển dụng để tìm hiểu nhu cầu nhân lực, các kỹ năng được yêu cầu nhiều nhất cũng như những khu vực có nhu cầu tuyển dụng cao. Thông qua việc ứng dụng các kiến thức của môn Khoa học dữ liệu, đề tài góp phần cung cấp cái nhìn tổng quan về thị trường lao động CNTT hiện nay.

Trong quá trình thực hiện đề tài, em đã vận dụng các công cụ và phương pháp phân tích dữ liệu để khai thác thông tin từ dữ liệu tuyển dụng, từ đó đưa ra các nhận xét và đánh giá phù hợp. Mặc dù đã cố gắng hoàn thiện nội dung một cách tốt nhất, nhưng do thời gian và kiến thức còn hạn chế nên báo cáo khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp của thầy để đề tài được hoàn thiện hơn.

Em xin chân thành cảm ơn Thầy Nguyễn Văn Huy đã tận tình hướng dẫn và hỗ trợ em trong suốt quá trình thực hiện đề tài.

LỜI CẢM ƠN

Để hoàn thành đề tài “Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam”, em đã nhận được sự hướng dẫn và hỗ trợ quý báu từ thầy cô và bạn bè trong suốt quá trình học tập và thực hiện báo cáo.

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc tới Thầy Nguyễn Văn Huy, giảng viên môn Khoa học dữ liệu, đã tận tình giảng dạy, hướng dẫn và tạo điều kiện thuận lợi để em hoàn thành đề tài này. Những kiến thức và kinh nghiệm mà thầy truyền đạt là nền tảng quan trọng giúp em thực hiện quá trình thu thập, xử lý và phân tích dữ liệu một cách hiệu quả.

Em cũng xin chân thành cảm ơn các thầy cô trong Khoa Công nghệ Thông tin đã trang bị cho em những kiến thức chuyên môn cần thiết trong suốt quá trình học tập tại trường.

Cuối cùng, em xin cảm ơn gia đình và bạn bè đã luôn động viên, hỗ trợ và tạo điều kiện thuận lợi để em hoàn thành tốt báo cáo này.

Do kiến thức và kinh nghiệm còn hạn chế nên báo cáo khó tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của thầy để báo cáo được hoàn thiện hơn.

Em xin chân thành cảm ơn!

CHƯƠNG 1: TỔNG QUAN

1.1. Đặt vấn đề

Trong những năm gần đây, cùng với sự phát triển mạnh mẽ của cuộc Cách mạng công nghiệp 4.0 và quá trình chuyển đổi số trên phạm vi toàn cầu, ngành Công nghệ thông tin (CNTT) đã trở thành một trong những lĩnh vực có tốc độ phát triển nhanh nhất tại Việt Nam. Các doanh nghiệp thuộc nhiều lĩnh vực khác nhau như tài chính, ngân hàng, thương mại điện tử, giáo dục, y tế và sản xuất đều có nhu cầu ứng dụng công nghệ để nâng cao hiệu quả hoạt động. Điều này làm gia tăng đáng kể nhu cầu tuyển dụng nguồn nhân lực CNTT có trình độ chuyên môn cao.

Song song với đó, thị trường lao động CNTT cũng liên tục thay đổi theo sự phát triển của công nghệ. Những kỹ năng được doanh nghiệp yêu cầu hôm nay có thể khác biệt đáng kể so với vài năm trước. Các lĩnh vực như Trí tuệ nhân tạo (AI), Khoa học dữ liệu (Data Science), Điện toán đám mây (Cloud Computing), DevOps hay An toàn thông tin đang ngày càng được quan tâm và mở ra nhiều cơ hội việc làm mới.

Sự phát triển của các trang tuyển dụng trực tuyến đã tạo ra nguồn dữ liệu lớn về thị trường lao động CNTT. Các dữ liệu này chứa nhiều thông tin giá trị như vị trí tuyển dụng, kỹ năng yêu cầu, địa điểm làm việc, kinh nghiệm, mức lương và đánh giá doanh nghiệp. Nếu được khai thác hiệu quả, nguồn dữ liệu này có thể giúp nhận diện xu hướng tuyển dụng, nhu cầu nhân lực cũng như các kỹ năng đang được doanh nghiệp ưu tiên.

Vì vậy, việc áp dụng các phương pháp của Khoa học dữ liệu để phân tích dữ liệu tuyển dụng CNTT là cần thiết và có ý nghĩa thực tiễn cao. Kết quả phân tích không chỉ giúp doanh nghiệp hiểu rõ hơn về thị trường lao động mà còn hỗ trợ sinh viên và người lao động định hướng học tập, phát triển kỹ năng và lựa chọn nghề nghiệp phù hợp với nhu cầu thực tế.

1.2. Lý do chọn đề tài

Ngành CNTT hiện đang là một trong những ngành có nhu cầu tuyển dụng cao nhất tại Việt Nam. Tuy nhiên, do sự thay đổi nhanh chóng của công nghệ, yêu cầu tuyển dụng của doanh nghiệp cũng thay đổi liên tục. Điều này khiến nhiều sinh viên và người lao động gặp khó khăn trong việc xác định những kỹ năng cần học tập và phát triển để đáp ứng nhu cầu của thị trường.

Bên cạnh đó, lượng dữ liệu tuyển dụng được đăng tải hằng ngày trên các nền tảng việc làm là rất lớn. Đây là nguồn dữ liệu thực tế, phản ánh trực tiếp nhu cầu tuyển dụng của doanh nghiệp. Việc khai thác và phân tích nguồn dữ liệu này có thể cung cấp

hiều thông tin hữu ích về xu hướng nghề nghiệp, kỹ năng phổ biến, các vị trí đang có nhu cầu cao cũng như đặc điểm của thị trường lao động CNTT hiện nay.

Ngoài ý nghĩa thực tiễn, đề tài còn tạo điều kiện để vận dụng các kiến thức đã học trong môn Khoa học dữ liệu như thu thập dữ liệu, làm sạch dữ liệu, phân tích dữ liệu khám phá (EDA), trực quan hóa dữ liệu, xây dựng mô hình phân lớp và phân cụm. Đây là cơ hội giúp người thực hiện nâng cao kỹ năng xử lý dữ liệu và tiếp cận các bài toán thực tế trong lĩnh vực CNTT.

Từ những lý do trên, nhóm lựa chọn thực hiện đề tài “Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam” nhằm tìm hiểu đặc điểm của thị trường lao động CNTT và ứng dụng các phương pháp Khoa học dữ liệu vào việc khai thác, phân tích dữ liệu tuyển dụng.

1.3. Mục tiêu của đề tài

1.3.1. Mục tiêu tổng quát

Đề tài “Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam” được thực hiện nhằm ứng dụng các phương pháp của Khoa học dữ liệu để khai thác và phân tích bộ dữ liệu tuyển dụng CNTT tại Việt Nam. Thông qua quá trình thu thập, xử lý, phân tích và trực quan hóa dữ liệu, đề tài hướng tới việc nhận diện các xu hướng tuyển dụng nổi bật trên thị trường lao động, xác định những kỹ năng được doanh nghiệp quan tâm và đánh giá nhu cầu nhân lực của các nhóm nghề trong lĩnh vực CNTT.

Bên cạnh đó, đề tài còn áp dụng các kỹ thuật học máy để xây dựng mô hình dự đoán và phân nhóm nghề nghiệp dựa trên các kỹ năng được yêu cầu trong tin tuyển dụng. Kết quả nghiên cứu góp phần cung cấp cái nhìn tổng quan về thị trường tuyển dụng CNTT tại Việt Nam, đồng thời hỗ trợ sinh viên, người lao động và doanh nghiệp trong việc định hướng học tập, phát triển kỹ năng và xây dựng chiến lược tuyển dụng phù hợp với nhu cầu thực tế.

1.3.2. Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát đã đề ra, đề tài tập trung nghiên cứu bộ dữ liệu IT Jobs Dataset nhằm khai thác các thông tin liên quan đến hoạt động tuyển dụng trong lĩnh vực Công nghệ thông tin tại Việt Nam. Trước hết, đề tài tiến hành tìm hiểu cấu trúc dữ liệu, thực hiện các bước tiền xử lý như làm sạch dữ liệu, loại bỏ các giá trị không hợp lệ, xử lý dữ liệu thiếu và chuẩn hóa dữ liệu để đảm bảo chất lượng cho quá trình phân tích.

Sau khi hoàn thành giai đoạn tiền xử lý, đề tài thực hiện phân tích dữ liệu khám phá nhằm làm rõ đặc điểm của thị trường tuyển dụng CNTT. Nội dung nghiên cứu tập

trung vào việc xác định những khu vực có nhu cầu tuyển dụng cao, đánh giá mức độ tập trung của các cơ hội việc làm theo từng thành phố và tìm hiểu sự phân bố của các vị trí tuyển dụng trên thị trường lao động.

Đề tài đồng thời nghiên cứu các kỹ năng chuyên môn xuất hiện trong các tin tuyển dụng nhằm xác định những công nghệ, công cụ và ngôn ngữ lập trình đang được doanh nghiệp ưu tiên. Việc phân tích tần suất xuất hiện của các kỹ năng giúp phản ánh nhu cầu thực tế của thị trường đối với nguồn nhân lực CNTT trong giai đoạn hiện nay.

Ngoài việc nghiên cứu từng kỹ năng riêng lẻ, đề tài còn xem xét mối liên hệ giữa các kỹ năng để phát hiện những nhóm kỹ năng thường được yêu cầu đồng thời trong cùng một vị trí tuyển dụng. Kết quả này giúp xây dựng bức tranh rõ nét hơn về yêu cầu chuyên môn của doanh nghiệp đối với người lao động.

Bên cạnh các nội dung phân tích dữ liệu, đề tài áp dụng các thuật toán học máy để giải quyết hai bài toán thực tế. Thứ nhất là xây dựng mô hình phân lớp nhằm dự đoán một vị trí tuyển dụng thuộc nhóm nghề nghiệp nào dựa trên tập kỹ năng được yêu cầu. Thứ hai là áp dụng phương pháp phân cụm để nhóm các vị trí tuyển dụng có đặc điểm kỹ năng tương đồng thành những nhóm nghề nghiệp khác nhau. Qua đó, đề tài đánh giá khả năng ứng dụng của các kỹ thuật Khoa học dữ liệu trong việc phân tích và hỗ trợ ra quyết định trong lĩnh vực tuyển dụng nhân sự CNTT.

1.4. Phạm vi nghiên cứu

Đề tài sử dụng bộ dữ liệu IT Jobs Dataset, bao gồm các thông tin tuyển dụng thuộc lĩnh vực Công nghệ thông tin tại Việt Nam. Các thuộc tính được sử dụng trong nghiên cứu bao gồm tên vị trí tuyển dụng, công ty tuyển dụng, địa điểm làm việc, kỹ năng yêu cầu, kinh nghiệm làm việc, mức độ đánh giá của doanh nghiệp và các thông tin liên quan khác.

Nội dung nghiên cứu tập trung vào việc phân tích xu hướng tuyển dụng, đánh giá nhu cầu nhân lực CNTT, phân tích kỹ năng nghề nghiệp và xây dựng các mô hình học máy dựa trên dữ liệu tuyển dụng. Các kết quả thu được phản ánh đặc điểm của thị trường lao động trong phạm vi bộ dữ liệu nghiên cứu và được sử dụng nhằm mục đích học tập, nghiên cứu trong môn Khoa học dữ liệu.

Đề tài không đi sâu vào các yếu tố kinh tế, chính sách lao động hoặc các yếu tố xã hội ảnh hưởng đến hoạt động tuyển dụng. Đồng thời, nghiên cứu chỉ tập trung vào dữ liệu tuyển dụng ngành CNTT mà không mở rộng sang các lĩnh vực nghề nghiệp khác.

1.5. Phương pháp nghiên cứu

Đề tài được thực hiện theo quy trình Khoa học dữ liệu gồm nhiều giai đoạn liên tiếp, từ thu thập dữ liệu đến xây dựng và đánh giá mô hình học máy.

Trước tiên, bộ dữ liệu IT Jobs Dataset được thu thập và nghiên cứu nhằm xác định các thuộc tính cần thiết cho quá trình phân tích. Sau đó, dữ liệu được tiền xử lý thông qua các bước làm sạch dữ liệu, loại bỏ giá trị trùng lặp, xử lý dữ liệu thiếu và chuẩn hóa định dạng nhằm nâng cao chất lượng dữ liệu đầu vào.

Tiếp theo, đề tài sử dụng phương pháp phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA) để tìm hiểu đặc điểm của dữ liệu, phát hiện các xu hướng tuyển dụng và đánh giá mối quan hệ giữa các thuộc tính. Các kết quả phân tích được trực quan hóa bằng biểu đồ nhằm hỗ trợ việc quan sát và diễn giải dữ liệu một cách trực quan hơn.

Sau giai đoạn phân tích, các thuật toán học máy được áp dụng để giải quyết các bài toán đặt ra. Đối với bài toán dự đoán nhóm nghề nghiệp, đề tài sử dụng phương pháp phân lớp để xây dựng mô hình nhận dạng nghề nghiệp dựa trên tập kỹ năng yêu cầu. Đối với bài toán khám phá cấu trúc thị trường lao động, đề tài sử dụng phương pháp phân cụm nhằm nhóm các vị trí tuyển dụng có đặc điểm tương đồng thành các nhóm nghề nghiệp khác nhau.

Cuối cùng, kết quả của các mô hình được đánh giá thông qua các chỉ số phù hợp và so sánh với mục tiêu nghiên cứu ban đầu. Từ đó, đề tài đưa ra các nhận xét, đánh giá và kết luận về xu hướng tuyển dụng ngành CNTT tại Việt Nam cũng như khả năng ứng dụng của các phương pháp Khoa học dữ liệu trong lĩnh vực này.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về Khoa học dữ liệu

Khoa học dữ liệu là một lĩnh vực liên ngành, kết hợp giữa toán học, thống kê, khoa học máy tính và kiến thức chuyên ngành nhằm thu thập, xử lý, phân tích và khai thác thông tin có giá trị từ dữ liệu. Trong bối cảnh dữ liệu ngày càng được tạo ra với khối lượng lớn, tốc độ nhanh và nhiều định dạng khác nhau, Khoa học dữ liệu giữ vai trò quan trọng trong việc hỗ trợ con người hiểu rõ hơn về các hiện tượng, xu hướng và quy luật ẩn chứa bên trong dữ liệu.

Mục tiêu chính của Khoa học dữ liệu không chỉ là lưu trữ hay quản lý dữ liệu, mà còn là biến dữ liệu thô thành thông tin có ý nghĩa. Thông qua các phương pháp phân tích, thống kê, trực quan hóa và học máy, dữ liệu có thể được sử dụng để hỗ trợ ra quyết định, dự đoán xu hướng và giải quyết các bài toán thực tế trong nhiều lĩnh vực như kinh tế, giáo dục, y tế, thương mại điện tử, tài chính và tuyển dụng nhân sự.

Trong một dự án Khoa học dữ liệu, dữ liệu ban đầu thường chưa hoàn chỉnh và có thể chứa nhiều vấn đề như giá trị thiếu, dữ liệu trùng lặp, sai định dạng hoặc không thống nhất. Vì vậy, trước khi tiến hành phân tích, dữ liệu cần được làm sạch và chuẩn hóa. Đây là bước quan trọng giúp nâng cao chất lượng dữ liệu và đảm bảo kết quả phân tích có độ tin cậy cao hơn.

Quy trình thực hiện một bài toán Khoa học dữ liệu thường bao gồm các giai đoạn cơ bản như: xác định vấn đề cần giải quyết, thu thập dữ liệu, tiền xử lý dữ liệu, phân tích dữ liệu khám phá, xây dựng mô hình, đánh giá kết quả và trình bày kết quả. Các giai đoạn này có mối liên hệ chặt chẽ với nhau. Nếu dữ liệu đầu vào không đảm bảo chất lượng thì kết quả phân tích và mô hình dự đoán có thể bị sai lệch.

Trong đề tài “Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam”, Khoa học dữ liệu được sử dụng để khai thác bộ dữ liệu IT Jobs Dataset. Thông qua việc phân tích các thông tin như thành phố tuyển dụng, vị trí công việc, kỹ năng yêu cầu và đánh giá công ty, đề tài hướng tới việc nhận diện những xu hướng nổi bật của thị trường tuyển dụng CNTT. Bên cạnh đó, các kỹ thuật học máy cũng được áp dụng để dự đoán nhóm nghề nghiệp và phân cụm các vị trí tuyển dụng dựa trên đặc điểm kỹ năng.

Việc ứng dụng Khoa học dữ liệu vào phân tích tuyển dụng có ý nghĩa thực tiễn cao. Đối với sinh viên và người lao động, kết quả phân tích giúp xác định những kỹ năng cần thiết để đáp ứng nhu cầu thị trường. Đối với doanh nghiệp, kết quả này hỗ trợ đánh giá xu hướng nguồn nhân lực và xây dựng chiến lược tuyển dụng phù hợp. Đối với cơ sở đào tạo, việc phân tích dữ liệu tuyển dụng giúp điều chỉnh nội dung đào tạo theo hướng sát với thực tế hơn.

2.2. Phân tích dữ liệu khám phá (EDA)

Phân tích dữ liệu khám phá, hay Exploratory Data Analysis (EDA), là một bước quan trọng trong quy trình Khoa học dữ liệu. Đây là quá trình tìm hiểu dữ liệu thông qua các phương pháp thống kê mô tả và trực quan hóa nhằm phát hiện các đặc điểm, xu hướng, mối quan hệ và bất thường trong dữ liệu. Trước khi xây dựng mô hình học máy, EDA giúp người nghiên cứu hiểu rõ dữ liệu đang có gì, dữ liệu phân bố như thế nào và có những vấn đề nào cần xử lý.

EDA không chỉ đơn thuần là việc tạo ra biểu đồ, mà còn là quá trình đặt câu hỏi và tìm kiếm câu trả lời từ dữ liệu. Thông qua EDA, người phân tích có thể phát hiện dữ liệu bị thiếu, dữ liệu bị trùng lặp, các giá trị ngoại lai hoặc các mối quan hệ tiềm ẩn giữa các biến. Đây là cơ sở quan trọng để lựa chọn phương pháp xử lý dữ liệu và mô hình phù hợp.

Trong phân tích dữ liệu tuyển dụng CNTT, EDA giúp làm rõ nhiều đặc điểm của thị trường lao động. Ví dụ, có thể xác định thành phố nào có số lượng tin tuyển dụng CNTT cao nhất, vị trí công việc nào xuất hiện nhiều nhất, kỹ năng nào được yêu cầu nhiều nhất, hoặc các kỹ năng nào thường được yêu cầu cùng nhau trong một tin tuyển dụng. Những kết quả này giúp phản ánh nhu cầu thực tế của doanh nghiệp đối với nguồn nhân lực CNTT.

Một trong những kỹ thuật thường dùng trong EDA là thống kê tần suất. Kỹ thuật này cho biết một giá trị xuất hiện bao nhiêu lần trong dữ liệu. Trong đề tài này, thống kê tần suất được sử dụng để đếm số lượng tin tuyển dụng theo thành phố, số lần xuất hiện của từng vị trí công việc và số lần xuất hiện của từng kỹ năng. Từ đó, có thể xác định những thành phố, vị trí và kỹ năng nổi bật nhất trong bộ dữ liệu.

Bên cạnh thống kê tần suất, trực quan hóa dữ liệu cũng là một phần quan trọng của EDA. Các biểu đồ giúp trình bày dữ liệu dưới dạng trực quan, dễ quan sát và dễ so

sánh hơn so với bảng số liệu thuần túy. Biểu đồ cột thường được sử dụng để so sánh số lượng tin tuyển dụng giữa các thành phố hoặc các vị trí công việc. Biểu đồ phân tán có thể dùng để quan sát mối quan hệ giữa số lượng kỹ năng và đánh giá công ty. Biểu đồ nhiệt có thể hỗ trợ biểu diễn mức độ xuất hiện cùng nhau giữa các kỹ năng.

Trong đề tài này, EDA đóng vai trò nền tảng cho toàn bộ quá trình nghiên cứu. Các kết quả EDA không chỉ giúp trả lời các nội dung phân tích dữ liệu mà còn cung cấp cơ sở để xây dựng mô hình học máy ở các bước tiếp theo. Nếu quá trình EDA được thực hiện tốt, người nghiên cứu sẽ hiểu rõ hơn về dữ liệu, từ đó lựa chọn đặc trưng phù hợp và nâng cao chất lượng mô hình.

2.3. Học máy trong phân tích dữ liệu

Học máy là một lĩnh vực của trí tuệ nhân tạo, cho phép máy tính học từ dữ liệu để đưa ra dự đoán hoặc phát hiện quy luật mà không cần lập trình cụ thể cho từng tình huống. Thay vì chỉ thực hiện các lệnh cố định, mô hình học máy có khả năng rút ra mẫu từ dữ liệu huấn luyện và áp dụng những mẫu đó cho dữ liệu mới.

Trong phân tích dữ liệu, học máy thường được sử dụng khi dữ liệu có khối lượng lớn hoặc có nhiều đặc trưng phức tạp mà con người khó phân tích bằng phương pháp thủ công. Học máy có thể hỗ trợ dự đoán kết quả, phân loại đối tượng, phát hiện nhóm dữ liệu tương đồng hoặc nhận diện các mẫu ẩn trong dữ liệu.

Các phương pháp học máy thường được chia thành ba nhóm chính: học có giám sát, học không giám sát và học tăng cường. Học có giám sát sử dụng dữ liệu đã có nhãn để huấn luyện mô hình, ví dụ như dự đoán nhóm nghề nghiệp của một tin tuyển dụng dựa trên kỹ năng. Học không giám sát sử dụng dữ liệu chưa có nhãn để tìm ra cấu trúc hoặc nhóm dữ liệu tiềm ẩn, ví dụ như phân cụm các vị trí tuyển dụng có kỹ năng tương đồng. Học tăng cường thường được sử dụng trong các bài toán ra quyết định theo chuỗi hành động.

Trong đề tài này, học máy được sử dụng với hai mục đích chính. Thứ nhất, mô hình phân lớp được xây dựng để dự đoán một vị trí tuyển dụng thuộc nhóm nghề nghiệp nào dựa trên các kỹ năng yêu cầu. Thứ hai, phương pháp phân cụm được áp dụng để chia các vị trí tuyển dụng thành những nhóm nghề nghiệp có đặc điểm kỹ năng tương đồng. Hai bài toán này giúp khai thác dữ liệu ở mức sâu hơn so với phân tích thống kê thông thường.

Việc áp dụng học máy trong phân tích dữ liệu tuyển dụng CNTT có nhiều ý nghĩa. Mô hình phân lớp có thể hỗ trợ tự động nhận diện nhóm nghề cho các tin tuyển dụng mới. Trong khi đó, mô hình phân cụm giúp phát hiện các nhóm nghề đang tồn tại trong dữ liệu mà không cần xác định trước nhãn. Nhờ đó, kết quả nghiên cứu vừa có tính mô tả, vừa có khả năng hỗ trợ dự đoán và khám phá tri thức mới.

2.3.1. Bài toán phân lớp

Phân lớp là một bài toán thuộc nhóm học có giám sát. Trong bài toán này, mô hình được huấn luyện từ tập dữ liệu đã biết trước nhãn. Sau quá trình huấn luyện, mô hình có thể dự đoán nhãn cho các dữ liệu mới chưa biết trước kết quả. Đây là một trong những bài toán phổ biến nhất trong học máy.

Ví dụ, trong lĩnh vực tuyển dụng CNTT, một tin tuyển dụng có thể thuộc các nhóm nghề như Backend Developer, Frontend Developer, Data Analyst, Data Scientist, AI Engineer, DevOps Engineer hoặc Mobile Developer. Mỗi tin tuyển dụng thường có danh sách kỹ năng yêu cầu khác nhau. Dựa trên danh sách kỹ năng này, mô hình phân lớp có thể học cách nhận biết đặc điểm của từng nhóm nghề và dự đoán nhóm nghề tương ứng cho các tin tuyển dụng mới.

Quy trình xây dựng mô hình phân lớp thường gồm nhiều bước. Đầu tiên, dữ liệu cần được chuẩn bị và gán nhãn. Tiếp theo, các đặc trưng đầu vào được trích xuất từ dữ liệu. Trong đề tài này, đặc trưng đầu vào chủ yếu là các kỹ năng xuất hiện trong tin tuyển dụng. Sau đó, dữ liệu được chia thành tập huấn luyện và tập kiểm tra. Mô hình được huấn luyện trên tập huấn luyện và được đánh giá trên tập kiểm tra để xem khả năng dự đoán có tốt hay không.

Một số thuật toán thường được sử dụng cho bài toán phân lớp gồm Decision Tree, Random Forest, Naive Bayes, K-Nearest Neighbors, Support Vector Machine và Logistic Regression. Trong đề tài này, thuật toán Random Forest được lựa chọn do có khả năng xử lý dữ liệu nhiều đặc trưng, độ chính xác tương đối tốt và ít bị ảnh hưởng bởi nhiễu so với một cây quyết định đơn lẻ.

Để đánh giá mô hình phân lớp, có thể sử dụng các chỉ số như Accuracy, Precision, Recall và F1-score. Accuracy cho biết tỷ lệ dự đoán đúng trên tổng số mẫu. Precision thể hiện mức độ chính xác của các dự đoán thuộc một lớp. Recall cho biết khả năng mô hình tìm đúng các mẫu thực sự thuộc một lớp. F1-score là chỉ số kết hợp

giữa Precision và Recall, thường được sử dụng khi dữ liệu giữa các lớp không cân bằng.

Trong đề tài này, bài toán phân lớp giúp dự đoán nhóm nghề nghiệp của các vị trí tuyển dụng CNTT dựa trên kỹ năng yêu cầu. Kết quả mô hình có thể hỗ trợ việc tự động phân loại tin tuyển dụng và giúp người học định hướng rõ hơn về nhóm kỹ năng cần có cho từng nghề nghiệp.

2.3.2. Bài toán phân cụm

Phân cụm là một bài toán thuộc nhóm học không giám sát. Khác với phân lớp, phân cụm không sử dụng dữ liệu đã có nhãn. Mục tiêu của phân cụm là chia các đối tượng trong dữ liệu thành nhiều nhóm sao cho các đối tượng trong cùng một nhóm có mức độ tương đồng cao, còn các đối tượng ở các nhóm khác nhau thì có sự khác biệt lớn hơn.

Trong phân tích dữ liệu tuyển dụng CNTT, phân cụm có thể được sử dụng để nhóm các vị trí tuyển dụng dựa trên kỹ năng yêu cầu. Những tin tuyển dụng có nhiều kỹ năng giống nhau sẽ có xu hướng được xếp vào cùng một cụm. Ví dụ, các tin yêu cầu HTML, CSS, JavaScript và React có thể nằm trong một cụm liên quan đến Frontend. Các tin yêu cầu Python, SQL, Machine Learning và Data Analysis có thể nằm trong cụm liên quan đến dữ liệu.

Phân cụm có ý nghĩa quan trọng khi người nghiên cứu muốn khám phá cấu trúc tiềm ẩn trong dữ liệu. Trong nhiều trường hợp, dữ liệu không có sẵn nhãn nghề nghiệp hoặc nhãn không rõ ràng. Khi đó, phân cụm giúp tìm ra các nhóm tự nhiên dựa trên sự tương đồng về đặc trưng. Kết quả phân cụm có thể được phân tích để đặt tên cho các nhóm nghề nghiệp và hiểu rõ đặc điểm của từng nhóm.

Quy trình thực hiện phân cụm thường bao gồm các bước như lựa chọn đặc trưng, chuẩn hóa dữ liệu, xác định số cụm phù hợp, áp dụng thuật toán phân cụm và đánh giá kết quả. Trong đề tài này, đặc trưng dùng để phân cụm chủ yếu dựa trên tập kỹ năng yêu cầu trong các tin tuyển dụng. Các kỹ năng được mã hóa thành dạng số để thuật toán có thể xử lý.

Một số thuật toán phân cụm phổ biến gồm K-Means, Hierarchical Clustering và DBSCAN. Trong đó, K-Means là thuật toán đơn giản, dễ triển khai và phù hợp với các

bài toán cần chia dữ liệu thành số cụm xác định trước. Vì vậy, K-Means được lựa chọn để phân nhóm các vị trí tuyển dụng CNTT trong đề tài.

Kết quả phân cụm giúp bổ sung góc nhìn cho kết quả phân tích dữ liệu. Nếu phân lớp trả lời câu hỏi một tin tuyển dụng thuộc nhóm nghề nào dựa trên nhãn đã biết, thì phân cụm giúp phát hiện các nhóm nghề dựa trên sự tương đồng của dữ liệu mà không cần nhãn ban đầu.

2.4. Một số thuật toán sử dụng trong đề tài

Trong đề tài này, hai thuật toán học máy chính được sử dụng là Random Forest và K-Means. Random Forest được sử dụng cho bài toán phân lớp nhóm nghề nghiệp, còn K-Means được sử dụng cho bài toán phân cụm các vị trí tuyển dụng dựa trên kỹ năng yêu cầu. Hai thuật toán này đại diện cho hai hướng tiếp cận khác nhau trong học máy: học có giám sát và học không giám sát.

Việc lựa chọn Random Forest và K-Means phù hợp với mục tiêu nghiên cứu của đề tài. Random Forest giúp dự đoán nhóm nghề nghiệp dựa trên dữ liệu đã được gán nhãn, trong khi K-Means giúp khám phá các nhóm nghề nghiệp có đặc điểm tương đồng mà không cần nhãn ban đầu. Sự kết hợp giữa hai thuật toán giúp đề tài vừa có khả năng dự đoán, vừa có khả năng khám phá cấu trúc dữ liệu.

2.4.1. Thuật toán Random Forest

Random Forest là thuật toán học máy thuộc nhóm học có giám sát, thường được sử dụng cho các bài toán phân lớp và hồi quy. Thuật toán này được xây dựng dựa trên sự kết hợp của nhiều cây quyết định. Mỗi cây quyết định đưa ra một kết quả dự đoán riêng, sau đó Random Forest tổng hợp kết quả của các cây để đưa ra dự đoán cuối cùng.

Cây quyết định là một mô hình học máy có cấu trúc giống như một cây, trong đó mỗi nút đại diện cho một điều kiện kiểm tra trên dữ liệu, mỗi nhánh là kết quả của điều kiện đó và mỗi lá là một nhãn dự đoán. Tuy nhiên, nếu chỉ sử dụng một cây quyết định đơn lẻ, mô hình có thể dễ bị quá khớp với dữ liệu huấn luyện. Điều này có nghĩa là mô hình học quá kỹ dữ liệu cũ nhưng lại dự đoán kém trên dữ liệu mới.

Random Forest khắc phục hạn chế này bằng cách xây dựng nhiều cây quyết định khác nhau trên các tập dữ liệu con được lấy mẫu ngẫu nhiên từ dữ liệu ban đầu. Đồng thời, tại mỗi lần chia nhánh, thuật toán cũng chỉ xem xét một số thuộc tính ngẫu

nhiên thay vì toàn bộ thuộc tính. Nhờ vậy, các cây trong rừng có sự khác biệt với nhau, giúp mô hình tổng hợp được nhiều góc nhìn và giảm nguy cơ quá khớp.

Đối với bài toán phân lớp, mỗi cây trong Random Forest sẽ đưa ra một dự đoán về lớp của mẫu dữ liệu. Kết quả cuối cùng được xác định dựa trên nguyên tắc bỏ phiếu đa số. Lớp nào được nhiều cây dự đoán nhất sẽ trở thành kết quả cuối cùng của mô hình.

Random Forest có nhiều ưu điểm phù hợp với đề tài. Thứ nhất, thuật toán có khả năng xử lý dữ liệu có nhiều đặc trưng, đặc biệt phù hợp với dữ liệu kỹ năng tuyển dụng vì mỗi kỹ năng có thể được xem như một đặc trưng riêng. Thứ hai, Random Forest thường cho kết quả ổn định và có độ chính xác cao hơn so với một cây quyết định đơn lẻ. Thứ ba, thuật toán ít bị ảnh hưởng bởi nhiễu và có khả năng làm việc tốt với dữ liệu phức tạp.

Tuy nhiên, Random Forest cũng có một số hạn chế. Do sử dụng nhiều cây quyết định, mô hình có thể tốn nhiều thời gian huấn luyện hơn so với một số thuật toán đơn giản. Ngoài ra, kết quả của Random Forest khó giải thích hơn so với một cây quyết định riêng lẻ vì mô hình là sự kết hợp của nhiều cây. Dù vậy, trong phạm vi đề tài, ưu điểm của Random Forest vẫn phù hợp với mục tiêu dự đoán nhóm nghề nghiệp dựa trên kỹ năng yêu cầu.

Trong đề tài này, Random Forest được sử dụng để dự đoán nhóm nghề nghiệp của một vị trí tuyển dụng CNTT. Dữ liệu đầu vào của mô hình là các kỹ năng được yêu cầu trong tin tuyển dụng, sau khi đã được xử lý và chuyển đổi thành dạng số. Dữ liệu đầu ra là nhóm nghề nghiệp tương ứng. Kết quả mô hình giúp đánh giá khả năng tự động phân loại vị trí tuyển dụng dựa trên đặc điểm kỹ năng.

2.4.2. Thuật toán K-Means

K-Means là một thuật toán phân cụm thuộc nhóm học không giám sát. Thuật toán này được sử dụng để chia dữ liệu thành K cụm khác nhau dựa trên mức độ tương đồng giữa các điểm dữ liệu. Mục tiêu của K-Means là làm cho các điểm trong cùng một cụm càng giống nhau càng tốt và các cụm khác nhau càng tách biệt càng tốt.

Ý tưởng cơ bản của K-Means là xác định K tâm cụm, sau đó gán mỗi điểm dữ liệu vào cụm có tâm gần nhất. Sau khi các điểm đã được gán vào cụm, thuật toán tính lại vị trí tâm cụm dựa trên trung bình của các điểm trong cụm đó. Quá trình gán điểm

và cập nhật tâm cụm được lặp lại nhiều lần cho đến khi các tâm cụm gần như không thay đổi hoặc đạt đến số lần lặp tối đa.

Trong bài toán phân cụm dữ liệu tuyển dụng CNTT, mỗi vị trí tuyển dụng được biểu diễn thông qua tập kỹ năng yêu cầu. Những vị trí có kỹ năng tương đồng sẽ có khoảng cách gần nhau hơn trong không gian đặc trưng và có xu hướng được xếp vào cùng một cụm. Nhờ đó, K-Means có thể giúp phát hiện các nhóm nghề nghiệp dựa trên đặc điểm kỹ năng mà không cần nhãn nghề nghiệp ban đầu.

Một vấn đề quan trọng khi sử dụng K-Means là lựa chọn số cụm K phù hợp. Nếu K quá nhỏ, các nhóm nghề khác nhau có thể bị gộp chung vào một cụm, làm mất thông tin chi tiết. Nếu K quá lớn, dữ liệu có thể bị chia quá nhỏ, khiến kết quả khó diễn giải. Vì vậy, cần sử dụng các phương pháp hỗ trợ như Elbow Method hoặc Silhouette Score để lựa chọn số cụm phù hợp hơn.

K-Means có ưu điểm là đơn giản, dễ hiểu, dễ triển khai và có tốc độ xử lý nhanh với dữ liệu có kích thước vừa phải. Thuật toán phù hợp với các bài toán cần khám phá nhóm dữ liệu dựa trên sự tương đồng. Trong đề tài này, K-Means được sử dụng để nhóm các vị trí tuyển dụng CNTT thành những cụm nghề nghiệp có đặc điểm kỹ năng tương tự nhau.

L-Tuy nhiên, K-Means cũng có một số hạn chế. Kết quả phân cụm phụ thuộc vào số cụm K được chọn ban đầu và vị trí khởi tạo tâm cụm. Ngoài ra, K-Means hoạt động tốt hơn với dữ liệu có dạng cụm rõ ràng và có thể kém hiệu quả nếu dữ liệu có hình dạng phức tạp hoặc chứa nhiều nhiễu. Vì vậy, sau khi phân cụm, cần phân tích và đánh giá kết quả để đảm bảo các cụm có ý nghĩa thực tế.

M-Trong phạm vi đề tài, K-Means được sử dụng như một công cụ hỗ trợ khám phá cấu trúc của dữ liệu tuyển dụng CNTT. Kết quả phân cụm giúp nhận diện các nhóm vị trí có kỹ năng tương đồng, từ đó đưa ra nhận xét về các nhóm nghề nghiệp phổ biến trên thị trường lao động CNTT tại Việt Nam.

CHƯƠNG 3: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

3.1. Kiến trúc hệ thống phân tích dữ liệu

3.1.1. Sơ đồ khối hệ thống

Hệ thống phân tích xu hướng tuyển dụng ngành Công nghệ thông tin tại Việt Nam được xây dựng theo mô hình xử lý dữ liệu tuần tự. Dữ liệu đầu vào của hệ thống là bộ dữ liệu IT Jobs Dataset, sau đó dữ liệu được đưa qua các bước xử lý, phân tích, xây dựng mô hình học máy và hiển thị kết quả. Mục tiêu của hệ thống là khai thác thông tin có giá trị từ dữ liệu tuyển dụng, từ đó hỗ trợ việc nhận diện xu hướng việc làm CNTT tại Việt Nam

Sơ đồ khối tổng quát của hệ thống gồm các khối chính: khối dữ liệu đầu vào, khối tiền xử lý dữ liệu, khối phân tích dữ liệu khám phá, khối xây dựng mô hình học máy, khối đánh giá kết quả và khối hiển thị kết quả. Các khối này có quan hệ nối tiếp nhau, trong đó đầu ra của khối trước là đầu vào cho khối sau.

Khối dữ liệu đầu vào có nhiệm vụ cung cấp dữ liệu tuyển dụng CNTT cho toàn bộ hệ thống. Dữ liệu bao gồm các thông tin như tên công việc, tên công ty, thành phố làm việc, kỹ năng yêu cầu, kinh nghiệm, mức lương và đánh giá công ty. Đây là nguồn dữ liệu quan trọng phục vụ cho cả quá trình phân tích và xây dựng mô hình


Khối tiền xử lý dữ liệu có nhiệm vụ làm sạch và chuẩn hóa dữ liệu. Trong thực tế, dữ liệu tuyển dụng thường tồn tại các vấn đề như thiếu dữ liệu, dữ liệu trùng lặp, dữ liệu không đúng định dạng hoặc danh sách kỹ năng chưa được tách riêng. Vì vậy, khối này giúp dữ liệu trở nên nhất quán và phù hợp hơn cho các bước xử lý tiếp theo

Khối phân tích dữ liệu khám phá được sử dụng để thống kê, trực quan hóa và phát hiện các xu hướng nổi bật trong dữ liệu. Từ khối này, hệ thống có thể đưa ra các kết quả như thành phố có nhu cầu tuyển dụng cao, vị trí CNTT được tuyển nhiều, kỹ năng phổ biến và mối quan hệ giữa các kỹ năng.

Khối xây dựng mô hình học máy gồm hai hướng xử lý chính. Thuật toán Random Forest được sử dụng để dự đoán nhóm nghề nghiệp của một vị trí tuyển dụng dựa trên kỹ năng yêu cầu. Thuật toán K-Means được sử dụng để phân cụm các vị trí tuyển dụng có đặc điểm kỹ năng tương đồng.

Cuối cùng, khối hiển thị kết quả có nhiệm vụ trình bày kết quả phân tích thông qua bảng số liệu, biểu đồ và các chỉ số đánh giá. Nhờ đó, người dùng có thể dễ dàng

quan sát, so sánh và rút ra nhận xét về xu hướng tuyển dụng ngành CNTT tại Việt Nam.



Hình 3.1: Sơ đồ khối hệ thống phân tích dữ liệu

3.1.2. Quy trình hoạt động của hệ thống

Quy trình hoạt động của hệ thống được xây dựng theo các bước rõ ràng, bắt đầu từ việc nạp dữ liệu đầu vào cho đến khi đưa ra kết quả phân tích và đánh giá mô hình. Quy trình này giúp đảm bảo dữ liệu được xử lý đúng trình tự, hạn chế sai sót và nâng cao độ tin cậy của kết quả nghiên cứu.

Bước đầu tiên là đọc dữ liệu từ bộ IT Jobs Dataset. Dữ liệu được nạp vào chương trình bằng Python, sau đó hệ thống kiểm tra thông tin tổng quan của bộ dữ liệu như số dòng, số cột, tên các thuộc tính, kiểu dữ liệu và số lượng giá trị thiếu. Đây là bước quan trọng giúp người thực hiện nắm được cấu trúc ban đầu của dữ liệu.

Bước thứ hai là tiền xử lý dữ liệu. Ở bước này, hệ thống tiến hành làm sạch dữ liệu bằng cách xử lý giá trị thiếu, loại bỏ bản ghi trùng lặp, chuẩn hóa dữ liệu dạng chữ và chuyển đổi các cột cần thiết về đúng kiểu dữ liệu. Đối với cột kỹ năng, dữ liệu được tách thành danh sách các kỹ năng riêng biệt để phục vụ cho việc thống kê và mã hóa trong mô hình học máy.

Bước thứ ba là phân tích dữ liệu khám phá. Dữ liệu sau khi được xử lý sẽ được sử dụng để phân tích các nội dung chính của đề tài. Hệ thống thực hiện thống kê số lượng tin tuyển dụng theo thành phố, thống kê các vị trí công việc phổ biến, thống kê

kỹ năng được yêu cầu nhiều nhất, phân tích các kỹ năng thường xuất hiện cùng nhau và đánh giá mối quan hệ giữa số lượng kỹ năng với đánh giá công ty.

Bước thứ tư là xây dựng mô hình học máy. Với bài toán phân lớp, dữ liệu kỹ năng được mã hóa thành dạng số để huấn luyện mô hình Random Forest. Mô hình này có nhiệm vụ dự đoán nhóm nghề nghiệp của vị trí tuyển dụng. Với bài toán phân cụm, thuật toán K-Means được sử dụng để nhóm các vị trí tuyển dụng có đặc điểm kỹ năng tương đồng.

Bước cuối cùng là đánh giá và hiển thị kết quả. Các kết quả phân tích được trình bày thông qua biểu đồ cột, biểu đồ phân tán, bảng thống kê hoặc các chỉ số đánh giá mô hình. Dựa trên các kết quả này, đề tài đưa ra nhận xét về xu hướng tuyển dụng ngành CNTT tại Việt Nam.

3.1.3. Các chức năng chính của hệ thống

Hệ thống được xây dựng nhằm hỗ trợ quá trình phân tích dữ liệu tuyển dụng CNTT và xây dựng mô hình học máy. Các chức năng chính của hệ thống được thiết kế phù hợp với mục tiêu của đề tài và bám sát quy trình xử lý dữ liệu.

Chức năng đầu tiên là đọc và quản lý dữ liệu tuyển dụng. Hệ thống có khả năng nạp dữ liệu từ tệp CSV, kiểm tra dữ liệu ban đầu và hiển thị các thông tin tổng quan như số lượng bản ghi, số lượng thuộc tính, kiểu dữ liệu và các giá trị thiếu. Chức năng này giúp người thực hiện nắm được tình trạng dữ liệu trước khi xử lý.

Chức năng thứ hai là tiền xử lý dữ liệu. Hệ thống thực hiện các thao tác làm sạch dữ liệu như xử lý dữ liệu thiếu, loại bỏ dữ liệu trùng lặp, chuẩn hóa dữ liệu chữ, tách danh sách kỹ năng và chuyển đổi dữ liệu về dạng phù hợp. Đây là chức năng quan trọng vì chất lượng dữ liệu ảnh hưởng trực tiếp đến kết quả phân tích và mô hình học máy.

Chức năng thứ ba là phân tích dữ liệu khám phá. Hệ thống thực hiện thống kê và trực quan hóa dữ liệu nhằm tìm ra các xu hướng nổi bật trong thị trường tuyển dụng CNTT. Các nội dung phân tích bao gồm nhu cầu tuyển dụng theo thành phố, vị trí tuyển dụng phổ biến, kỹ năng được yêu cầu nhiều nhất, các kỹ năng thường xuất hiện cùng nhau và mối quan hệ giữa số lượng kỹ năng với đánh giá công ty.

Chức năng thứ tư là xây dựng mô hình phân lớp. Hệ thống sử dụng thuật toán Random Forest để dự đoán nhóm nghề nghiệp của một vị trí tuyển dụng dựa trên các

kỹ năng yêu cầu. Chức năng này giúp tự động hóa việc nhận diện nhóm nghề từ dữ liệu tuyển dụng.

Chức năng thứ năm là xây dựng mô hình phân cụm. Hệ thống sử dụng thuật toán K-Means để nhóm các vị trí tuyển dụng có đặc điểm kỹ năng tương đồng. Kết quả phân cụm giúp phát hiện các nhóm nghề nghiệp tiềm ẩn trong dữ liệu.

Chức năng cuối cùng là hiển thị kết quả. Hệ thống trình bày kết quả dưới dạng bảng, biểu đồ và các chỉ số đánh giá, giúp người dùng dễ quan sát và đưa ra nhận xét.

3.2. Thiết kế thuật toán

3.2.1. Thuật toán tiền xử lý dữ liệu

Tiền xử lý dữ liệu là bước đầu tiên và có vai trò quan trọng trong quá trình xây dựng hệ thống phân tích dữ liệu. Dữ liệu tuyển dụng thực tế thường chưa hoàn chỉnh, có thể chứa giá trị thiếu, dữ liệu trùng lặp, sai định dạng hoặc các trường dữ liệu chưa phù hợp để phân tích. Vì vậy, cần thực hiện tiền xử lý để đảm bảo dữ liệu đầu vào có chất lượng tốt.

Thuật toán tiền xử lý dữ liệu bắt đầu bằng việc đọc bộ dữ liệu IT Jobs Dataset từ tệp CSV. Sau khi dữ liệu được nạp vào chương trình, hệ thống tiến hành kiểm tra tổng quan dữ liệu, bao gồm số lượng dòng, số lượng cột, kiểu dữ liệu của từng thuộc tính và số lượng giá trị bị thiếu. Việc kiểm tra này giúp xác định những vấn đề cần xử lý trong bộ dữ liệu.

Tiếp theo, hệ thống xử lý các giá trị thiếu. Với các cột quan trọng như vị trí tuyển dụng, thành phố hoặc kỹ năng, nếu dữ liệu bị thiếu nghiêm trọng thì bản ghi có thể bị loại bỏ. Với một số thuộc tính khác như đánh giá công ty hoặc mức lương, có thể chuyển đổi về dạng số và xử lý các giá trị không hợp lệ.

Sau đó, hệ thống thực hiện chuẩn hóa dữ liệu. Các dữ liệu dạng văn bản được đưa về cùng một định dạng, loại bỏ khoảng trắng thừa và chuẩn hóa cách viết. Đối với trường kỹ năng, hệ thống tách chuỗi kỹ năng thành danh sách các kỹ năng riêng biệt. Đây là bước quan trọng vì kỹ năng là thuộc tính chính được sử dụng cho cả phân tích dữ liệu và xây dựng mô hình học máy.

Cuối cùng, hệ thống tạo thêm các đặc trưng mới phục vụ nghiên cứu, ví dụ như số lượng kỹ năng trong mỗi tin tuyển dụng hoặc nhóm nghề nghiệp của vị trí tuyển

dụng. Sau khi hoàn thành tiền xử lý, dữ liệu được lưu lại dưới dạng phù hợp để sử dụng cho các bước tiếp theo.



Hình 3.2. Lưu đồ thuật toán tiền xử lý dữ liệu

3.2.2. Thuật toán phân tích dữ liệu khám phá (EDA)

Thuật toán phân tích dữ liệu khám phá được sử dụng để khai thác các thông tin quan trọng từ bộ dữ liệu tuyển dụng CNTT. Sau khi dữ liệu đã được tiền xử lý, hệ thống thực hiện các phép thống kê và trực quan hóa nhằm nhận diện xu hướng tuyển dụng trên thị trường.

Đầu tiên, hệ thống phân tích nhu cầu tuyển dụng theo thành phố. Dữ liệu trong cột thành phố được tách và thống kê tần suất xuất hiện. Kết quả cho biết thành phố nào có số lượng tin tuyển dụng CNTT cao nhất, từ đó phản ánh khu vực có nhu cầu nhân lực CNTT lớn.

Tiếp theo, hệ thống thống kê các vị trí tuyển dụng phổ biến. Dựa trên tên công việc hoặc nhóm nghề nghiệp, hệ thống đếm số lượng tin tuyển dụng theo từng vị trí.

Nội dung này giúp xác định các nhóm nghề đang được tuyển nhiều trên thị trường như lập trình viên, phân tích dữ liệu, kiểm thử phần mềm hoặc kỹ sư hệ thống.

Sau đó, hệ thống phân tích kỹ năng được yêu cầu nhiều nhất. Các kỹ năng trong mỗi tin tuyển dụng được tách riêng và thống kê tần suất xuất hiện. Kết quả giúp xác định những kỹ năng quan trọng mà doanh nghiệp thường yêu cầu, ví dụ như Python, SQL, JavaScript, Java, React hoặc Machine Learning.

Ngoài ra, hệ thống còn phân tích sự xuất hiện đồng thời giữa các kỹ năng. Những kỹ năng thường đi cùng nhau trong cùng một tin tuyển dụng có thể phản ánh các bộ kỹ năng cần thiết cho từng nhóm nghề. Ví dụ, HTML, CSS và JavaScript thường liên quan đến nhóm Frontend; Python, SQL và Machine Learning thường liên quan đến nhóm dữ liệu.

Cuối cùng, hệ thống phân tích mối quan hệ giữa số lượng kỹ năng yêu cầu và đánh giá công ty. Mục tiêu là xem xét liệu các công ty có đánh giá cao có xu hướng yêu cầu nhiều kỹ năng hơn hay không. Kết quả được trực quan hóa bằng biểu đồ phù hợp để hỗ trợ nhận xét.

3.2.3. Thuật toán phân lớp Random Forest

Thuật toán Random Forest được sử dụng trong đề tài để giải quyết bài toán dự đoán nhóm nghề nghiệp của một vị trí tuyển dụng dựa trên các kỹ năng yêu cầu. Đây là bài toán học có giám sát, trong đó dữ liệu đầu vào là tập kỹ năng và dữ liệu đầu ra là nhóm nghề nghiệp tương ứng.


Trước khi huấn luyện mô hình, dữ liệu kỹ năng cần được chuyển đổi sang dạng số. Vì các thuật toán học máy không thể xử lý trực tiếp danh sách kỹ năng dạng văn bản, hệ thống sử dụng phương pháp mã hóa kỹ năng để biểu diễn mỗi kỹ năng thành một đặc trưng. Nếu một tin tuyển dụng có chứa kỹ năng đó thì giá trị đặc trưng là 1, ngược lại là 0.

Sau khi mã hóa dữ liệu, hệ thống chia dữ liệu thành hai phần: tập huấn luyện và tập kiểm tra. Tập huấn luyện được sử dụng để mô hình học các quy luật giữa kỹ năng và nhóm nghề nghiệp. Tập kiểm tra được dùng để đánh giá khả năng dự đoán của mô hình trên dữ liệu chưa từng thấy.

Tiếp theo, mô hình Random Forest được huấn luyện. Random Forest hoạt động bằng cách xây dựng nhiều cây quyết định khác nhau. Mỗi cây đưa ra một kết quả dự

đoán riêng, sau đó mô hình tổng hợp kết quả bằng cách lấy lớp được nhiều cây lựa chọn nhất. Cách tiếp cận này giúp mô hình ổn định hơn và giảm hiện tượng quá khớp so với một cây quyết định đơn lẻ.

Sau khi huấn luyện, mô hình được sử dụng để dự đoán nhóm nghề nghiệp trên tập kiểm tra. Kết quả dự đoán được so sánh với nhãn thực tế để đánh giá độ chính xác. Các chỉ số như Accuracy, Precision, Recall và F1-score có thể được sử dụng để đánh giá hiệu quả mô hình.



Hình 3.3. Lưu đồ thuật toán Random Forest

3.2.4. Thuật toán phân cụm K-Means


Thuật toán K-Means được sử dụng để phân nhóm các vị trí tuyển dụng CNTT dựa trên sự tương đồng về kỹ năng yêu cầu. Khác với Random Forest, K-Means là thuật toán học không giám sát, nghĩa là không cần nhãn nhóm nghề nghiệp ban đầu. Mục tiêu của thuật toán là tìm ra các nhóm dữ liệu có đặc điểm giống nhau.

Đầu vào của thuật toán K-Means là dữ liệu kỹ năng đã được mã hóa thành dạng số. Mỗi tin tuyển dụng được biểu diễn bằng một vector kỹ năng. Những tin tuyển dụng có nhiều kỹ năng giống nhau sẽ có khoảng cách gần nhau hơn trong không gian đặc trưng và có xu hướng được xếp vào cùng một cụm.

Trước khi thực hiện phân cụm, hệ thống cần xác định số cụm K phù hợp. Nếu số cụm quá ít, các nhóm nghề khác nhau có thể bị gộp chung. Nếu số cụm quá nhiều, kết quả phân cụm có thể bị chia nhỏ và khó diễn giải. Vì vậy, số cụm cần được lựa chọn dựa trên đặc điểm dữ liệu và kết quả thực nghiệm.

Sau khi chọn số cụm, thuật toán K-Means tiến hành khởi tạo các tâm cụm, gán mỗi điểm dữ liệu vào cụm gần nhất, sau đó cập nhật lại tâm cụm. Quá trình này được lặp lại cho đến khi các tâm cụm ổn định hoặc đạt số lần lặp tối đa.

Kết quả của thuật toán là mỗi tin tuyển dụng được gán vào một cụm nhất định. Sau đó, hệ thống phân tích các kỹ năng nổi bật trong từng cụm để đặt tên hoặc giải thích ý nghĩa của cụm. Ví dụ, một cụm có nhiều kỹ năng HTML, CSS, JavaScript có thể được nhận xét là nhóm Frontend; cụm có Python, SQL, Machine Learning có thể liên quan đến nhóm dữ liệu.



Hình 3.4. Lưu đồ thuật toán K-Means

3.3. Thiết kế dữ liệu

3.3.1. Giới thiệu bộ dữ liệu IT Jobs Dataset

Bộ dữ liệu được sử dụng trong đề tài là IT Jobs Dataset, chứa các thông tin liên quan đến tuyển dụng ngành Công nghệ thông tin tại Việt Nam. Bộ dữ liệu này phản ánh các thông tin cơ bản của tin tuyển dụng như vị trí công việc, công ty tuyển dụng, thành phố làm việc, kỹ năng yêu cầu, kinh nghiệm, mức lương và đánh giá công ty.

Dữ liệu này phù hợp với mục tiêu nghiên cứu của đề tài vì nó cung cấp đầy đủ các thông tin cần thiết để phân tích xu hướng tuyển dụng ngành CNTT. Thông qua bộ dữ liệu, có thể đánh giá nhu cầu tuyển dụng theo khu vực, xác định các vị trí công việc phổ biến, thống kê các kỹ năng được yêu cầu nhiều nhất và xây dựng các mô hình học máy dựa trên kỹ năng.

Trong phạm vi đề tài, bộ dữ liệu được sử dụng cho hai nhóm nhiệm vụ chính. Nhóm nhiệm vụ thứ nhất là phân tích dữ liệu khám phá nhằm tìm ra các xu hướng nổi bật trong thị trường tuyển dụng. Nhóm nhiệm vụ thứ hai là xây dựng mô hình học máy để dự đoán nhóm nghề nghiệp và phân cụm các vị trí tuyển dụng dựa trên đặc điểm kỹ năng.

3.3.2. Mô tả các trường dữ liệu

Bộ dữ liệu IT Jobs Dataset gồm nhiều trường thông tin khác nhau. Mỗi trường dữ liệu có ý nghĩa riêng và được sử dụng cho những mục đích phân tích khác nhau trong đề tài.

STT	Trường dữ liệu	Ý nghĩa
1	job_title	Tên vị trí tuyển dụng hoặc chức danh công việc
2	company_name	Tên công ty đăng tin tuyển dụng
3	city	Thành phố hoặc khu vực làm việc
4	skills	Danh sách kỹ năng được yêu cầu trong tin tuyển dụng
5	experience	Kinh nghiệm làm việc được yêu cầu
6	salary	Mức lương hoặc khoảng lương nếu có
7	rating	Điểm đánh giá của công ty
8	job_description	Mô tả công việc
9	company_type	Loại hình công ty nếu dữ liệu có cung cấp
10	posted_date	Thời gian đăng tin tuyển dụng nếu dữ liệu có cung cấp

Trong đó, các trường quan trọng nhất đối với đề tài là job_title, city, skills và rating. Trường job_title giúp xác định vị trí tuyển dụng và nhóm nghề nghiệp. Trường city được sử dụng để phân tích nhu cầu tuyển dụng theo khu vực. Trường skills là thuộc tính quan trọng nhất vì được dùng cho cả phân tích kỹ năng, phân lớp Random Forest và phân cụm K-Means. Trường rating được sử dụng để phân tích mối quan hệ giữa số lượng kỹ năng yêu cầu và đánh giá công ty.

3.3.3. Các thuộc tính được sử dụng trong nghiên cứu

Trong quá trình nghiên cứu, không phải tất cả các thuộc tính trong bộ dữ liệu đều được sử dụng. Đề tài lựa chọn các thuộc tính có liên quan trực tiếp đến mục tiêu phân tích và xây dựng mô hình.

Thuộc tính city được sử dụng để phân tích nhu cầu tuyển dụng theo thành phố. Thông qua việc thống kê số lượng tin tuyển dụng ở từng thành phố, đề tài có thể xác định khu vực nào có thị trường việc làm CNTT phát triển mạnh và thu hút nhiều doanh nghiệp tuyển dụng.

Thuộc tính job_title được sử dụng để phân tích các vị trí tuyển dụng phổ biến. Ngoài ra, thuộc tính này cũng có thể được dùng để xác định nhóm nghề nghiệp phục vụ cho bài toán phân lớp. Các vị trí có tên gọi khác nhau nhưng cùng tính chất công việc có thể được gom vào cùng một nhóm nghề.

Thuộc tính skills được sử dụng xuyên suốt trong đề tài. Đây là thuộc tính quan trọng nhất vì phản ánh yêu cầu chuyên môn của doanh nghiệp đối với ứng viên. Từ thuộc tính này, đề tài thực hiện thống kê kỹ năng phổ biến, phân tích kỹ năng thường xuất hiện cùng nhau, đồng thời mã hóa kỹ năng để xây dựng mô hình Random Forest và K-Means.

Thuộc tính rating được sử dụng để phân tích mối quan hệ giữa số lượng kỹ năng yêu cầu và đánh giá công ty. Việc phân tích thuộc tính này giúp tìm hiểu xem các công ty có điểm đánh giá cao có xu hướng yêu cầu nhiều kỹ năng hơn hay không.

Ngoài các thuộc tính chính, một số thuộc tính như experience và salary có thể được sử dụng bổ sung nếu dữ liệu đảm bảo đầy đủ và hợp lệ. Các thuộc tính này giúp mở rộng khả năng phân tích, chẳng hạn như đánh giá mối quan hệ giữa kinh nghiệm, mức lương và vị trí công việc.

3.4. Xây dựng hệ thống

3.4.1. Môi trường phát triển

Hệ thống được xây dựng bằng ngôn ngữ lập trình Python, đây là ngôn ngữ phổ biến trong lĩnh vực Khoa học dữ liệu nhờ cú pháp đơn giản, dễ sử dụng và có nhiều thư viện hỗ trợ mạnh mẽ. Python phù hợp với các thao tác xử lý dữ liệu, phân tích thống kê, trực quan hóa và xây dựng mô hình học máy.

Môi trường thực hiện chính của đề tài là Jupyter Notebook. Đây là môi trường thuận tiện cho việc viết mã, chạy từng bước xử lý, hiển thị bảng dữ liệu, biểu đồ và ghi chú giải thích. Jupyter Notebook đặc biệt phù hợp với các bài toán phân tích dữ liệu vì cho phép người thực hiện quan sát kết quả ngay sau từng đoạn mã.

Các thư viện được sử dụng trong hệ thống gồm Pandas, NumPy, Matplotlib và Scikit-learn. Pandas được sử dụng để đọc, xử lý và phân tích dữ liệu dạng bảng. NumPy hỗ trợ các phép toán số học và xử lý mảng. Matplotlib được sử dụng để trực quan hóa dữ liệu thông qua các biểu đồ. Scikit-learn được sử dụng để xây dựng và đánh giá các mô hình học máy như Random Forest và K-Means.

Thành phần	Vai trò
Python	Ngôn ngữ lập trình chính
Jupyter Notebook	Môi trường viết và chạy chương trình
Pandas	Đọc, xử lý và phân tích dữ liệu
NumPy	Hỗ trợ tính toán số học
Matplotlib	Vẽ biểu đồ trực quan hóa dữ liệu
Scikit-learn	Xây dựng mô hình học máy

3.4.2. Xây dựng chương trình xử lý dữ liệu

Chương trình xử lý dữ liệu được xây dựng nhằm chuẩn bị dữ liệu đầu vào cho các bước phân tích và mô hình học máy. Đây là phần nền tảng của hệ thống vì dữ liệu sau xử lý càng tốt thì kết quả phân tích càng đáng tin cậy.

Đầu tiên, chương trình đọc dữ liệu từ tệp CSV bằng thư viện Pandas. Sau khi dữ liệu được nạp, chương trình hiển thị thông tin tổng quan như số lượng dòng, số lượng cột, tên các thuộc tính và kiểu dữ liệu. Việc kiểm tra này giúp phát hiện các vấn đề ban đầu của bộ dữ liệu.

Tiếp theo, chương trình thực hiện làm sạch dữ liệu. Các bản ghi trùng lặp được loại bỏ để tránh làm sai lệch kết quả thống kê. Các giá trị thiếu được xử lý tùy theo mức độ quan trọng của từng thuộc tính. Với các cột quan trọng như thành phố, vị trí tuyển dụng và kỹ năng, dữ liệu thiếu cần được xử lý cẩn thận vì có ảnh hưởng trực tiếp đến kết quả nghiên cứu.

Sau đó, chương trình chuẩn hóa dữ liệu dạng văn bản. Các chuỗi ký tự được loại bỏ khoảng trắng thừa, chuyển về định dạng thống nhất và tách thành các thành phần riêng khi cần thiết. Đặc biệt, trường kỹ năng được tách thành danh sách kỹ năng để phục vụ cho việc đếm tần suất, phân tích đồng xuất hiện và mã hóa dữ liệu cho mô hình học máy.

Cuối cùng, chương trình tạo thêm một số thuộc tính mới như số lượng kỹ năng của từng tin tuyển dụng. Thuộc tính này được sử dụng để phân tích mối quan hệ giữa số lượng kỹ năng yêu cầu và đánh giá công ty.

3.4.3. Xây dựng mô hình học máy

Sau khi dữ liệu đã được xử lý, hệ thống tiến hành xây dựng hai mô hình học máy chính là Random Forest và K-Means. Hai mô hình này được lựa chọn vì phù hợp với mục tiêu nghiên cứu của đề tài.

Đối với mô hình Random Forest, dữ liệu đầu vào là danh sách kỹ năng của các tin tuyển dụng. Trước khi đưa vào mô hình, danh sách kỹ năng được mã hóa thành dạng số. Sau đó, dữ liệu được chia thành tập huấn luyện và tập kiểm tra. Mô hình được huấn luyện trên tập huấn luyện để học mối quan hệ giữa kỹ năng và nhóm nghề nghiệp. Sau khi huấn luyện, mô hình dự đoán nhóm nghề nghiệp trên tập kiểm tra và được đánh giá bằng các chỉ số phù hợp.

Đối với mô hình K-Means, dữ liệu kỹ năng sau khi được mã hóa sẽ được sử dụng để phân cụm. Mỗi tin tuyển dụng được xem như một điểm dữ liệu trong không gian đặc trưng. Thuật toán K-Means nhóm các điểm dữ liệu có kỹ năng tương đồng vào cùng một cụm. Sau khi phân cụm, hệ thống phân tích các kỹ năng nổi bật trong từng cụm để đưa ra nhận xét về nhóm nghề nghiệp tương ứng.

Việc xây dựng hai mô hình giúp đề tài có thể khai thác dữ liệu ở hai khía cạnh khác nhau. Random Forest giúp dự đoán nhóm nghề nghiệp dựa trên dữ liệu đã biết nhãn, còn K-Means giúp khám phá các nhóm nghề nghiệp tiềm ẩn trong dữ liệu mà không cần nhãn ban đầu.

3.4.4. Giao diện và kết quả hiển thị

Trong phạm vi đề tài, hệ thống không xây dựng giao diện phần mềm độc lập mà sử dụng Jupyter Notebook để hiển thị kết quả phân tích và mô hình. Đây là cách triển

khai phù hợp với bài toán Khoa học dữ liệu vì cho phép kết hợp giữa mã nguồn, bảng dữ liệu, biểu đồ và phân nhận xét trong cùng một môi trường làm việc.

Kết quả hiển thị của hệ thống bao gồm các bảng thống kê, biểu đồ trực quan và kết quả đánh giá mô hình. Các biểu đồ được sử dụng để thể hiện số lượng tin tuyển dụng theo thành phố, các vị trí tuyển dụng phổ biến, kỹ năng được yêu cầu nhiều nhất, mối quan hệ giữa số lượng kỹ năng và đánh giá công ty. Những biểu đồ này giúp người đọc dễ dàng quan sát xu hướng và so sánh giữa các nhóm dữ liệu.

Đối với mô hình Random Forest, kết quả hiển thị gồm độ chính xác dự đoán và các chỉ số đánh giá mô hình. Những chỉ số này cho biết khả năng mô hình dự đoán đúng nhóm nghề nghiệp của các vị trí tuyển dụng.

Đối với mô hình K-Means, kết quả hiển thị gồm số cụm, danh sách các cụm và đặc điểm kỹ năng nổi bật của từng cụm. Kết quả này giúp nhận diện các nhóm nghề nghiệp có đặc điểm tương đồng trong thị trường tuyển dụng CNTT.

Nhìn chung, phần hiển thị kết quả giúp hoàn thiện hệ thống phân tích dữ liệu, giúp người thực hiện dễ dàng đánh giá, nhận xét và rút ra kết luận từ dữ liệu.

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ


4.1. Thực nghiệm

4.1.1. Kết quả phân tích nhu cầu tuyển dụng theo thành phố

Sau khi xử lý dữ liệu trong cột thành phố, chương trình tiến hành thống kê số lượng tin tuyển dụng CNTT theo từng khu vực. Kết quả cho thấy TP. Hồ Chí Minh là thành phố có nhu cầu tuyển dụng CNTT cao nhất với 1368 tin tuyển dụng. Đứng thứ hai là Hà Nội với 885 tin tuyển dụng. Các khu vực tiếp theo gồm District 1 với 190 tin, Cầu Giấy với 171 tin, Tân Bình với 157 tin và Đà Nẵng với 136 tin.

Kết quả này cho thấy nhu cầu tuyển dụng ngành CNTT tập trung chủ yếu tại hai trung tâm kinh tế lớn là TP. Hồ Chí Minh và Hà Nội. Đây là những khu vực tập trung nhiều doanh nghiệp công nghệ, công ty phần mềm, startup và các tập đoàn có nhu cầu tuyển dụng nhân sự CNTT cao. Đà Nẵng cũng xuất hiện trong nhóm thành phố có nhu cầu tuyển dụng, tuy nhiên số lượng tin tuyển dụng thấp hơn đáng kể so với TP. Hồ Chí Minh và Hà Nội.

Từ kết quả trên có thể nhận xét rằng thị trường việc làm CNTT tại Việt Nam có sự phân bố không đồng đều giữa các khu vực. Cơ hội việc làm tập trung nhiều ở các thành phố lớn, đặc biệt là TP. Hồ Chí Minh và Hà Nội. Điều này phù hợp với thực tế phát triển kinh tế và công nghệ tại Việt Nam hiện nay.



Hình 4.1. Biểu đồ số lượng tin tuyển dụng CNTT theo thành phố

4.1.2. Kết quả phân tích vị trí CNTT được tuyển dụng nhiều nhất


Ở phần phân tích vị trí tuyển dụng, chương trình thống kê số lượng tin tuyển dụng theo từng nhóm nghề CNTT. Kết quả cho thấy nhóm Khác / Không xác định chiếm số lượng lớn nhất. Điều này phản ánh rằng trong bộ dữ liệu có nhiều tin tuyển

dụng chưa được phân loại rõ ràng theo nhóm nghề, hoặc tên công việc có nhiều cách ghi khác nhau nên chương trình chưa nhận diện được chính xác.

Ngoài nhóm chưa xác định, các vị trí có số lượng tuyển dụng cao gồm Data / AI Engineer, Business Analyst, Backend Developer, Frontend Developer, Mobile Developer và DevOps Engineer. Trong đó, nhóm Data / AI Engineer và Business Analyst cho thấy nhu cầu về dữ liệu, trí tuệ nhân tạo và phân tích nghiệp vụ đang ngày càng được quan tâm trong thị trường CNTT.

Các vị trí Backend Developer, Frontend Developer và Mobile Developer vẫn giữ vai trò quan trọng vì đây là các nhóm nghề trực tiếp tham gia vào quá trình xây dựng phần mềm, website và ứng dụng di động. Bên cạnh đó, DevOps Engineer cũng xuất hiện trong nhóm vị trí phổ biến, cho thấy các doanh nghiệp ngày càng quan tâm đến triển khai, vận hành và tự động hóa hệ thống.

Tuy nhiên, do nhóm “Khác / Không xác định” có số lượng rất lớn, kết quả này cũng cho thấy bước phân loại vị trí tuyển dụng vẫn cần được cải thiện. Cần chuẩn hóa tên công việc tốt hơn để giảm số lượng bản ghi rơi vào nhóm chưa xác định, từ đó giúp kết quả phân tích chính xác hơn.



Hình 4.2. Biểu đồ những vị trí CNTT được tuyển dụng nhiều nhất

4.1.3. Kết quả phân tích kỹ năng CNTT được yêu cầu nhiều nhất


Sau khi tách danh sách kỹ năng từ các tin tuyển dụng, chương trình tiến hành thống kê tần suất xuất hiện của từng kỹ năng. Kết quả top 20 kỹ năng cho thấy các kỹ năng được yêu cầu nhiều nhất gồm Python, Java, ReactJS, MySQL, PHP, MongoDB,

NodeJS, Docker, Redis, AWS, JavaScript, Android, React Native, Kubernetes, VueJS, CSS, PostgreSQL và Angular.

Trong đó, Python và Java là hai kỹ năng xuất hiện nhiều nhất. Python thường được sử dụng trong phân tích dữ liệu, trí tuệ nhân tạo, học máy và phát triển backend. Java là ngôn ngữ lập trình phổ biến trong phát triển phần mềm doanh nghiệp, hệ thống lớn và ứng dụng backend. Việc hai kỹ năng này đứng đầu cho thấy thị trường tuyển dụng CNTT vẫn có nhu cầu cao đối với các ngôn ngữ lập trình nền tảng.

Các kỹ năng như ReactJS, JavaScript, VueJS, CSS và Angular phản ánh nhu cầu tuyển dụng trong lĩnh vực phát triển giao diện web. Trong khi đó, các kỹ năng như MySQL, MongoDB, PostgreSQL cho thấy cơ sở dữ liệu vẫn là một nhóm kỹ năng quan trọng. Ngoài ra, Docker, Kubernetes, Redis và AWS thể hiện xu hướng doanh nghiệp quan tâm đến triển khai hệ thống, điện toán đám mây và DevOps.

Tuy nhiên, trong một biểu đồ có xuất hiện giá trị nan với số lượng rất lớn. Đây là dấu hiệu cho thấy trong dữ liệu vẫn còn giá trị thiếu ở cột kỹ năng chưa được xử lý triệt để. Vì vậy, khi đưa vào báo cáo chính thức, cần ưu tiên sử dụng biểu đồ đã loại bỏ giá trị nan để kết quả phân tích kỹ năng chính xác và có ý nghĩa hơn.



Hình 4.3. Biểu đồ các kỹ năng CNTT được yêu cầu nhiều nhất


4.1.4. Kết quả phân tích mối liên hệ giữa các kỹ năng

Kết quả phân tích kỹ năng cho thấy các kỹ năng không xuất hiện riêng lẻ mà thường đi theo từng nhóm nhất định. Các kỹ năng liên quan đến phát triển web như JavaScript, ReactJS, VueJS, CSS, Angular thường xuất hiện cùng nhau, phản ánh nhóm kỹ năng đặc trưng của các vị trí Frontend Developer.

Bên cạnh đó, các kỹ năng như Python, MySQL, MongoDB, PostgreSQL thường liên quan đến các vị trí xử lý dữ liệu, backend hoặc phân tích dữ liệu. Các kỹ năng như Docker, Kubernetes, AWS, Redis thường xuất hiện trong các vị trí liên quan đến triển khai, vận hành hệ thống hoặc DevOps.

Việc phân tích mối liên hệ giữa các kỹ năng có ý nghĩa quan trọng vì nó giúp xác định không chỉ kỹ năng đơn lẻ nào được yêu cầu nhiều, mà còn cho thấy người học nên kết hợp các kỹ năng nào để phù hợp với từng nhóm nghề. Ví dụ, nếu định hướng theo Frontend thì cần học HTML/CSS, JavaScript và các framework như ReactJS hoặc VueJS. Nếu định hướng theo dữ liệu thì nên tập trung vào Python, SQL và các công cụ phân tích dữ liệu.

Kết quả này giúp sinh viên và người lao động có cái nhìn rõ hơn về các bộ kỹ năng cần thiết thay vì chỉ học từng kỹ năng riêng biệt.



Hình 4.4. Biểu đồ kỹ năng xuất hiện nhiều nhất

4.1.5. Kết quả phân tích mối quan hệ giữa số lượng kỹ năng và đánh giá công ty

Ở phần này, chương trình phân tích mối quan hệ giữa số lượng kỹ năng yêu cầu trong một tin tuyển dụng và điểm đánh giá trung bình của công ty. Kết quả thực nghiệm cho thấy số lượng mẫu phân tích là 2041. Hệ số tương quan Pearson đạt **0.082**.

Hệ số tương quan Pearson bằng 0.082 là rất thấp, cho thấy mối quan hệ giữa số lượng kỹ năng yêu cầu và đánh giá công ty gần như không đáng kể. Nói cách khác, không thể kết luận rằng công ty có đánh giá cao sẽ yêu cầu nhiều kỹ năng hơn, hoặc công ty yêu cầu nhiều kỹ năng thì sẽ có điểm đánh giá cao hơn.

Quan sát biểu đồ phân tán cũng cho thấy các điểm dữ liệu phân bố khá rải rác. Phần lớn điểm đánh giá công ty nằm trong khoảng từ 3.5 đến 5.0, trong khi số lượng kỹ năng yêu cầu có sự thay đổi nhưng không tạo thành xu hướng tăng hoặc giảm rõ ràng. Điều này cho thấy đánh giá công ty có thể chịu ảnh hưởng bởi nhiều yếu tố khác như môi trường làm việc, lương thưởng, văn hóa doanh nghiệp, chế độ đãi ngộ và trải nghiệm nhân viên, chứ không chỉ phụ thuộc vào số lượng kỹ năng trong tin tuyển dụng.

Kết quả này giúp đưa ra nhận xét rằng số lượng kỹ năng yêu cầu không phải là yếu tố quyết định trực tiếp đến mức độ đánh giá của công ty. Vì vậy, khi phân tích chất lượng công ty hoặc mức độ hấp dẫn của nhà tuyển dụng, cần kết hợp thêm nhiều thuộc tính khác ngoài số lượng kỹ năng.



Hình 4.5. Biểu đồ mối quan hệ giữa số lượng kỹ năng và đánh giá công ty


4.1.6. Kết quả mô hình phân lớp Random Forest

Mô hình Random Forest được sử dụng để dự đoán nhóm nghề nghiệp của một vị trí tuyển dụng dựa trên các kỹ năng yêu cầu. Kết quả được biểu diễn bằng biểu đồ so sánh số lượng nhóm nghề thực tế và nhóm nghề dự đoán.

Biểu đồ cho thấy nhóm Other chiếm số lượng lớn nhất trong cả dữ liệu thực tế và dữ liệu dự đoán. Số lượng dự đoán cho nhóm Other còn cao hơn số lượng thực tế. Điều này cho thấy mô hình có xu hướng dự đoán nhiều mẫu về nhóm Other. Nguyên nhân có thể do dữ liệu bị mất cân bằng, trong đó nhóm Other chiếm tỷ lệ quá lớn so với các nhóm nghề còn lại.

Đối với các nhóm nghề cụ thể như Frontend, Backend, AI, Data, Mobile và DevOps, số lượng mẫu thấp hơn rất nhiều so với nhóm Other. Điều này khiến mô hình khó học được đặc trưng rõ ràng của từng nhóm nghề nhỏ. Vì vậy, khả năng dự đoán của mô hình đối với các nhóm nghề ít dữ liệu có thể chưa cao.

Kết quả này cho thấy mô hình Random Forest đã có khả năng thực hiện bài toán phân lớp, tuy nhiên chất lượng mô hình còn phụ thuộc nhiều vào cách gán nhãn nhóm nghề và sự cân bằng dữ liệu giữa các lớp. Để cải thiện mô hình, cần giảm số lượng mẫu thuộc nhóm Other bằng cách chuẩn hóa tên công việc tốt hơn, bổ sung từ khóa phân loại nghề nghiệp và cân bằng lại dữ liệu huấn luyện.



Hình 4.6. Biểu đồ so sánh nhóm nghề thực tế và nhóm nghề dự đoán bằng Random Forest


4.1.7. Kết quả mô hình phân cụm K-Means

Thuật toán K-Means được sử dụng để phân cụm các vị trí tuyển dụng dựa trên kỹ năng yêu cầu. Kết quả thực nghiệm cho thấy nhóm nghề có số lượng lớn nhất sau phân cụm là Frontend với 2037 vị trí. Ngoài ra, biểu đồ còn xuất hiện nhóm Backend nhưng số lượng rất nhỏ so với nhóm Frontend.

Kết quả này cho thấy phần lớn dữ liệu sau khi phân cụm được gom vào một nhóm lớn. Điều này có thể phản ánh rằng đặc trưng kỹ năng trong dữ liệu chưa đủ tách biệt giữa các nhóm nghề, hoặc quá trình mã hóa kỹ năng và lựa chọn số cụm K chưa thực sự phù hợp. Ngoài ra, nếu trong dữ liệu có nhiều giá trị kỹ năng bị thiếu hoặc chưa được chuẩn hóa, thuật toán K-Means cũng có thể tạo ra kết quả phân cụm lệch.

Việc nhóm Frontend chiếm tới 2037 vị trí cho thấy kết quả phân cụm chưa thật sự cân bằng. Tuy nhiên, kết quả này vẫn có ý nghĩa trong việc thử nghiệm phương pháp học không giám sát để khám phá cấu trúc dữ liệu. Mô hình đã phân chia được các vị trí tuyển dụng thành các nhóm dựa trên kỹ năng, nhưng cần cải tiến thêm để các cụm có ý nghĩa rõ ràng hơn.

Để cải thiện kết quả phân cụm, cần xử lý kỹ hơn cột kỹ năng, loại bỏ giá trị thiếu, chuẩn hóa tên kỹ năng và thử nghiệm nhiều số cụm K khác nhau. Ngoài ra, có thể sử dụng các phương pháp đánh giá như Elbow Method hoặc Silhouette Score để lựa chọn số cụm phù hợp hơn.



Hình 4.7. Biểu đồ số lượng vị trí theo nhóm nghề sau phân cụm K-Means

4.1.8. Đánh giá chung kết quả thực nghiệm

Qua các kết quả thực nghiệm, đề tài đã thực hiện được các nội dung chính của bài toán phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam. Hệ thống đã xử lý được bộ dữ liệu IT Jobs Dataset, thực hiện phân tích nhu cầu tuyển dụng theo thành phố, phân tích vị trí tuyển dụng, phân tích kỹ năng, đánh giá mối quan hệ giữa số lượng kỹ năng và đánh giá công ty, đồng thời xây dựng hai mô hình học máy gồm Random Forest và K-Means.

Kết quả phân tích cho thấy nhu cầu tuyển dụng CNTT tập trung chủ yếu tại TP. Hồ Chí Minh và Hà Nội. Các kỹ năng lập trình và phát triển web như Python, Java, ReactJS, MySQL, PHP và JavaScript xuất hiện nhiều trong các tin tuyển dụng. Mối quan hệ giữa số lượng kỹ năng yêu cầu và đánh giá công ty không rõ ràng, thể hiện qua hệ số tương quan Pearson thấp.

Đối với phân học máy, mô hình Random Forest đã thực hiện được bài toán dự đoán nhóm nghề nghiệp, nhưng kết quả còn bị ảnh hưởng bởi sự mất cân bằng dữ liệu, đặc biệt là nhóm Other chiếm tỷ lệ lớn. Mô hình K-Means đã thực hiện được việc phân cụm nghề nghiệp, nhưng kết quả phân cụm còn lệch về một nhóm lớn, cần cải thiện thêm ở bước xử lý dữ liệu và lựa chọn số cụm.

Nhìn chung, kết quả thực nghiệm đáp ứng được mục tiêu của đề tài ở mức cơ bản. Đề tài đã chứng minh được khả năng ứng dụng Khoa học dữ liệu trong phân tích dữ liệu tuyển dụng CNTT. Tuy nhiên, để kết quả chính xác và có giá trị thực tiễn cao hơn, cần tiếp tục cải thiện chất lượng dữ liệu, chuẩn hóa kỹ năng và tối ưu các mô hình học máy.

4.2. Kết luận

4.2.1. Những kết quả đạt được

Đề tài “Phân tích xu hướng tuyển dụng ngành CNTT tại Việt Nam” đã xây dựng được quy trình phân tích dữ liệu tuyển dụng dựa trên bộ dữ liệu IT Jobs Dataset. Đề tài đã thực hiện các bước từ tiền xử lý dữ liệu, phân tích dữ liệu khám phá, trực quan hóa kết quả đến xây dựng mô hình học máy.

Về phân tích dữ liệu, đề tài đã xác định được TP. Hồ Chí Minh và Hà Nội là hai khu vực có nhu cầu tuyển dụng CNTT cao nhất. Đề tài cũng thống kê được các vị trí tuyển dụng phổ biến và các kỹ năng được yêu cầu nhiều trong thị trường CNTT. Kết quả cho thấy các kỹ năng như Python, Java, ReactJS, MySQL và PHP có tần suất xuất hiện cao.

Về mô hình học máy, đề tài đã xây dựng mô hình Random Forest để dự đoán nhóm nghề nghiệp dựa trên kỹ năng yêu cầu và mô hình K-Means để phân cụm các vị trí tuyển dụng có đặc điểm kỹ năng tương đồng. Mặc dù kết quả còn hạn chế, hai mô hình đã thể hiện được khả năng áp dụng học máy vào bài toán phân tích tuyển dụng.

4.2.2. Kiến thức và kỹ năng thu được

Thông qua đề tài, người thực hiện đã củng cố được kiến thức về quy trình Khoa học dữ liệu, bao gồm đọc dữ liệu, làm sạch dữ liệu, xử lý giá trị thiếu, chuẩn hóa dữ liệu, phân tích dữ liệu khám phá và trực quan hóa dữ liệu.

Ngoài ra, đề tài giúp người thực hiện hiểu rõ hơn về cách áp dụng các thuật toán học máy vào bài toán thực tế. Cụ thể, Random Forest được sử dụng cho bài toán

phân lớp, còn K-Means được sử dụng cho bài toán phân cụm. Quá trình thực hiện cũng giúp nâng cao kỹ năng sử dụng Python, Pandas, Matplotlib và Scikit-learn.

Bên cạnh kỹ năng lập trình, đề tài còn giúp rèn luyện khả năng phân tích kết quả, nhận xét biểu đồ và đánh giá hạn chế của mô hình. Đây là những kỹ năng quan trọng khi thực hiện các bài toán Khoa học dữ liệu trong thực tế.

4.2.3. Hạn chế của đề tài

Bên cạnh những kết quả đã đạt được, đề tài vẫn còn một số hạn chế. Thứ nhất, bộ dữ liệu còn tồn tại giá trị thiếu, thể hiện qua việc kỹ năng nan xuất hiện trong kết quả thống kê. Điều này cho thấy quá trình tiền xử lý dữ liệu cần được cải thiện thêm.

Thứ hai, kết quả phân loại vị trí tuyển dụng còn nhiều mẫu thuộc nhóm Khác / Không xác định hoặc Other. Điều này làm ảnh hưởng đến chất lượng phân tích vị trí tuyển dụng và mô hình Random Forest.

Thứ ba, kết quả phân cụm K-Means chưa cân bằng, khi phần lớn dữ liệu được gom vào một nhóm lớn. Điều này cho thấy cần thử nghiệm thêm cách mã hóa dữ liệu, lựa chọn số cụm và chuẩn hóa kỹ năng.

4.2.4. Hướng phát triển

Trong tương lai, đề tài có thể được cải thiện bằng cách làm sạch dữ liệu kỹ hơn, đặc biệt là xử lý các giá trị thiếu trong cột kỹ năng và chuẩn hóa tên kỹ năng. Ngoài ra, cần xây dựng bộ từ khóa phân loại nhóm nghề chi tiết hơn để giảm số lượng bản ghi thuộc nhóm Other hoặc Không xác định.

Đối với mô hình Random Forest, có thể cải thiện bằng cách cân bằng dữ liệu giữa các nhóm nghề và thử nghiệm thêm các thuật toán khác như Logistic Regression, Support Vector Machine hoặc XGBoost. Đối với mô hình K-Means, có thể sử dụng Elbow Method hoặc Silhouette Score để chọn số cụm phù hợp hơn.

Ngoài ra, đề tài có thể phát triển thêm giao diện dashboard để hiển thị kết quả phân tích một cách trực quan hơn. Nếu có thêm dữ liệu theo thời gian, hệ thống có thể mở rộng để phân tích xu hướng tuyển dụng CNTT theo từng năm hoặc từng giai đoạn.

TÀI LIỆU THAM KHẢO

- [1] Nguyễn Văn Huy, Bài giảng môn Khoa học dữ liệu, Trường Đại học Kỹ thuật Công nghiệp – Đại học Thái Nguyên, 2025.
- [2] Nguyễn Văn Huy, Giáo trình Khoa học dữ liệu, Trường Đại học Kỹ thuật Công nghiệp – Đại học Thái Nguyên, 2025.
- [3] Wes McKinney, Python for Data Analysis, 3rd Edition, O'Reilly Media, 2022.
- [4] Jake VanderPlas, Python Data Science Handbook, O'Reilly Media, 2016.